

Projet : Détection de fraude en e-commerce

1).But du projet : détecter les transactions frauduleuses en e-commerce. Le dataset contient des variables transactionnelles, client et comportementales

Cible (target) : fraudulent = 1 si la transaction est frauduleuse, 0 sinon.

2).Description des variables

Nom de la variable	Type	Description
transaction_id	id	Identifiant unique de la transaction
transaction_amount	numérique	Montant de la transaction (euros)
favourite_animal	catégorielle	Animal préféré du client
payment_method	catégorielle	Méthode de paiement (card, paypal, bank_transfer, apple_pay, google_pay)
astrological_sign	catégorielle	Signe astrologique du client
transaction_hour	numérique	Heure de la transaction (0–23)
delivery_time_days	numérique	Délai de livraison choisi (jours)
device_type	catégorielle	Type d'appareil (mobile, desktop, tablet)
browser_theme_color	catégorielle	Couleur thème du navigateur
ip_risk_score	numérique	Score de risque IP (0–100)
random_string	texte	Chaîne aléatoire sans signification
customer_age	numérique	Âge du client
customer_region	catégorielle	Région du client (EU, NA, APAC, LATAM, ME)
lucky_number	numérique	Numéro porte-bonheur
num_previous_transactions	numérique	Nombre de transactions précédentes
chargeback_history	binaire	Historique de chargebacks (0/1)
account_tenure_days	numérique	Ancienneté du compte (jours)
preferred_language	catégorielle	Langue préférée
num_items	numérique	Nombre d'articles achetés
discount_applied	binaire	Remise appliquée (0/1)
cart_abandon_rate	numérique	Taux d'abandon du panier (0-1)
time_on_site_sec	numérique	Temps passé sur le site (secondes)
browser_version_str	texte	Chaîne texte simulant version du navigateur
coupon_code_used	catégorielle	Code promo utilisé (None ou code)
purchase_channel	catégorielle	Canal (web, mobile_app, marketplace)
fraudulent	binaire	Cible : 1 = fraude, 0 = légitime

3) Plan et étapes couvertes

1. Jeu de données (18000 observations)
2. Vérifications et EDA
3. Prétraitement (imputation, encodage, scaling)
4. Construction de modèles : KNN, Bagging (base DecisionTree), RandomForest, XGBoost (boosting).
5. Évaluation : précision, rappel, F1, AUC ROC, matrice de confusion, comparaison cross-val.
6. Interprétabilité : importances, permutation importance
7. Recommandations pour production.