




Projet : Détection de fraude en e-commerce



Leila SALOUMI
Fabarika Tiebele Karama
M2 IREF- ERDS

CONTEXTE ET PROBLÉMATIQUE

Context

Dans le contexte du e-commerce, la multiplication des transactions en ligne s'accompagne d'un risque accru de fraude. Les entreprises doivent donc mettre en place des outils automatisés capables d'identifier rapidement les comportements suspects. Ce projet vise à développer un modèle de machine learning permettant de détecter les transactions frauduleuses à partir de données transactionnelles, comportementales et client. L'enjeu principal consiste à distinguer efficacement les fraudes des opérations légitimes, tout en limitant les erreurs de détection.

problématique

Comment concevoir un modèle de machine learning capable de détecter efficacement les transactions frauduleuses en e-commerce, tout en minimisant les faux positifs et les faux négatifs afin de garantir la sécurité des paiements sans nuire à l'expérience client ?

PRÉSENTATION DES DONNÉES

Chaque observation correspond à une transaction réalisée par un client, avec des informations à la fois transactionnelles, comportementales et client.

Volume des données :

- 18000 clients (le nombre de lignes)
- 23 caractéristiques (le nombre de colonnes)

avec 3 types de données différentes (numérique, catégorielle, texte)

```
transaction_id
transaction_amount
transaction_hour
delivery_time_days
ip_risk_score
customer_age
num_previous_transactions
chargeback_history
account_tenure_days
num_items
discount_applied
cart_abandon_rate
time_on_site_sec
lucky_number
fraudulent
```

```
payment_method
device_type
customer_region
preferred_language
favourite_animal
astrological_sign
browser_theme_color
random_string
browser_version_str
```


TRAITEMENT DES DONNÉES

Valeurs manquantes

La variable `customer_region` contient 25 % de valeurs manquantes.

Plutôt que d'imputer le mode, une catégorie "Unknown" a été créée pour éviter tout biais et préserver la distribution réelle.





Cette approche maintient la cohérence des données et peut révéler une information utile à la détection de fraude.



Suppression de 6 variables non informatives


- Les variables : `transaction_id`, `favourite_animal`, `astrological_sign`, `browser_theme_color`, `random_string` et `browser_version_str` ont été retirées.
- Elles présentaient une distribution uniforme ou aléatoire,
- apportant aucune valeur explicative au modèle.

ANALYSE UIVARIE DES VARIABLES QUALITATIVES



ANALYSE BIVARIEE DES VARIABLES QUALITATIVES

effet des interactions entre mode de paiement et région sur le taux de fraude




- Le taux de fraude est plus élevé pour la combinaison Google Pay × Moyen-Orient (≈15 %) que pour Bank Transfer × Europe (≈11 %).
- certaines interactions entre **méthode de paiement et région géographique influencent le risque de fraude, indiquant un effet conjoint potentiel entre les deux variables.

Taux de fraude selon la combinaison méthode de paiement / région

- Les taux de fraude varient selon la région et le moyen de paiement.
- Google Pay – ME présente le taux de fraude le plus élevé (14 %)
- Les transferts bancaires en Europe et APAC affichent également des lifts supérieurs à 1.5.
- PayPal – LATAM et Google Pay – APAC montrent des risques modérés.

	payment_method	customer_region	count	mean	lift
18	google_pay	ME	42	0.14	1.97
6	bank_transfer	EU	789	0.11	1.54
5	bank_transfer	APAC	279	0.11	1.53
22	paypal	LATAM	367	0.10	1.39
15	google_pay	APAC	138	0.09	1.30

test chi-2




- Les variables interaction_bt_eu, chargeback_history et payment_method sont significativement liées à la fraude (p-value < 0.05).
- Les autres variables catégorielles (langue, région, âge, nouveau client) n’ont aucun effet notable.
- Les interactions “virement bancaire × Europe”, l’historique de rétrofacturation et le mode de paiement sont les facteurs les plus associés à la fraude.

TABLEAU STATISTIQUES DES VARIABLES QUANTITATIVES ET MATRICE DE CORRELATION

	count	mean	std	min	25%	50%	75%	max
transaction_amount	18,000.00	79.32	79.11	0.00	22.85	54.92	110.32	759.66
transaction_hour	18,000.00	11.56	6.98	0.00	5.00	12.00	18.00	23.00
delivery_time_days	18,000.00	3.49	3.01	1.00	2.00	3.00	5.00	14.00
ip_risk_score	18,000.00	19.98	11.99	0.20	10.70	18.10	27.20	78.00
customer_age	18,000.00	48.63	17.83	18.00	33.00	49.00	64.00	79.00
num_previous_transactions	18,000.00	3.00	1.73	0.00	2.00	3.00	4.00	11.00
account_tenure_days	18,000.00	2,479.95	1,433.90	1.00	1,237.75	2,461.00	3,709.00	4,999.00
num_items	18,000.00	4.98	2.58	1.00	3.00	5.00	7.00	9.00
cart_abandon_rate	18,000.00	0.28	0.16	0.00	0.16	0.26	0.39	0.94
time_on_site_sec	18,000.00	187.13	108.93	0.00	102.00	179.00	261.00	718.00
lucky_number	18,000.00	49.88	28.62	1.00	25.00	50.00	75.00	99.00
fraudulent	18,000.00	0.07	0.26	0.00	0.00	0.00	0.00	1.00
interaction_bt_eu	18,000.00	0.04	0.20	0.00	0.00	0.00	0.00	1.00
interaction_gp_me	18,000.00	0.00	0.05	0.00	0.00	0.00	0.00	1.00



- fraudulent : taux moyen de fraude de 7 %, indiquant un jeu de données déséquilibré.
- transaction_amount : médiane 54,9 €, moyenne plus élevée → présence de montants extrêmes.
- ip_risk_score : 75 % des transactions < 27,2, donc majorité d'IP peu risquées.
- account_tenure_days : ancienneté moyenne de 2 480 jours (~6,8 ans) → comptes récents plus suspects.
- chargeback_history : 4 % des transactions concernent des comptes ayant déjà contesté un paiement, un signal fort de fraude.



La **matrice de corrélation** met en relation 11 variables numériques entre elles, ce qui exclue les autres variables non numériques


- Les corrélations entre variables numériques sont globalement faibles, peu de redondance dans les données.
- Aucune relation linéaire forte ($|r| > 0.7$) n'est observée entre les variables.

VISUALISATION DES DONNEES QUANTITATIVES



ANALYSE BIVARIÉE DES VARIABLES QUANTITATIVES SELON LE STATUT DE FRAUDE


account_tenure_days vs transaction_amount (fraude en rouge)




- Les transactions frauduleuses (en rouge) sont réparties uniformément parmi les transactions légitimes.
- Aucune concentration notable selon l'ancienneté du compte.
- La droite de régression horizontale montre l'absence de lien entre la durée de vie du compte et le montant des transactions.
- La fraude ne semble pas liée à l'âge du compte.

- Les fraudes (en rouge) sont diffusément réparties parmi les transactions normales.
- Aucun schéma clair ne relie le score IP au montant de la transaction.
- La droite de régression horizontale confirme l'absence de corrélation significative.
- 🖱️ Un score IP élevé n'est pas forcément associé à un montant plus important.

ip_risk_score vs transaction_amount (fraude en rouge)



time_on_site_sec vs transaction_amount (fraude en rouge)



- Les transactions frauduleuses sont dispersées parmi les transactions légitimes, sans zone spécifique ni tendance marquée.
- La droite de régression horizontale montre aucune corrélation entre le temps passé sur le site et le montant de la transaction.
- La rapidité d'achat ne constitue pas un indicateur fiable de fraude

PRÉPARATION DES DONNÉES

transformation des variables catégorielles


Les variables catégorielles ont été encodées via l'encodage one-hot ou l'encodage ordinal appliqué avec la méthode indicatrice imbriquée : `payment_method`, `device_type`, `customer_region`, `preferred_language`, `delivery_speed` et `age_group` ont été converties en valeurs numériques.

Transformation des variables numériques

Scaling (normalisation/standardisation) pour harmoniser les échelles et éviter un effet disproportionné sur le modèle.


SELECTION DES VARIABLES :

Step Forward Feature Selection




- L'algorithme SFS avec Random Forest a identifié les variables les plus contributives à la détection de fraude.
- Le score AUC optimal (~ 0.56) montre une amélioration modérée des performances.
- Les premières variables clés : num_items, payment_method_bank_transfer, device_type_desktop, interaction_bt_eu.
- Au-delà de 12–14 variables, le gain devient marginal, le modèle se stabilise.

Step Backward Feature Selection



- La méthode a retenu 38 variables optimales, avec un score AUC ≈ 0.54 .
- Amélioration modérée mais stable des performances du modèle.
- Variables clés : (num_items, time_on_site_se, transaction_amount, delivery_time_days, ip_risk_score, customer_region, preferred_language, age_group)

Algorithme génétique





- Score AUC optimal = 0.5814 avec 35 variables sélectionnées.
- Meilleure performance que les approches Forward et Backward.
- Variables clés : transaction_amount, ip_risk_score, num_previous_transactions, delivery_time_days, num_items, cart_abandon_rate, customer_region, preferred_language, age_group, chargeback_history.
- La fitness se stabilise autour de 0.58 après ~ 15 générations $\rightarrow$ convergence stable.



Recherche du "meilleur" algorithme de classification

modèle 1: K-Nearest Neighbors





--- Évaluation du Modèle KNN sur l'Ensemble de Test ---

Rapport de Classification :

	precision	recall	f1-score	support
Légitime (0)	0.93	1.00	0.96	3341
Fraude (1)	0.06	0.00	0.01	259
accuracy			0.92	3600
macro avg	0.49	0.50	0.48	3600
weighted avg	0.87	0.92	0.89	3600

modèle 2 : Bagging (avec Arbre de Décision)



Accuracy sur l'ensemble d'entraînement : 1.0000



Accuracy sur l'ensemble de test : 0.8522

Rapport de Classification sur l'ensemble de test :

	precision	recall	f1-score	support
Légitime	0.93	0.91	0.92	3341
Fraude	0.08	0.10	0.09	259
accuracy			0.85	3600
macro avg	0.50	0.50	0.50	3600
weighted avg	0.87	0.85	0.86	3600



Recherche du "meilleur" algorithme de classification

modèle 3: Random Forest



Rapport de Classification sur l'ensemble de test :

	precision	recall	f1-score	support
Légitime	0.93	1.00	0.96	3341
Fraude	0.00	0.00	0.00	259
accuracy			0.93	3600
macro avg	0.46	0.50	0.48	3600
weighted avg	0.86	0.93	0.89	3600



modèle 4: XGBoost



--- Évaluation du Modèle XGBoost sur l'Ensemble de Test ---
Accuracy: 89.75%

Rapport de Classification :

	precision	recall	f1-score	support
Légitime (0)	0.93	0.96	0.95	3341
Fraude (1)	0.11	0.06	0.08	259
accuracy			0.90	3600
macro avg	0.52	0.51	0.51	3600
weighted avg	0.87	0.90	0.88	3600

Recherche du "meilleur" algorithme de classification

modèle 4: Optimisation du Modèle XGBoost avec GridSearchCV




--- Évaluation du Modèle XGBoost Optimisé sur l'Ensemble de Test ---

Rapport de Classification (XGBoost Optimisé) :

	precision	recall	f1-score	support
Légitime (0)	0.94	0.72	0.82	3341
Fraude (1)	0.09	0.37	0.15	259
accuracy			0.70	3600
macro avg	0.52	0.55	0.48	3600
weighted avg	0.88	0.70	0.77	3600


Comparaison des ROC



Interprétabilité du Modèle Final (XGBoost Optimisé)


OBJECTIF : Identifier les variables les plus influentes dans les prédictions du modèle XGBoost final.

Analyse par Importance Intégrée




- Les variables les plus influentes sont payment_method_bank_transfer, customer_region_LATAM et preferred_language_de.
- Les facteurs liés au mode de paiement, à la région et au type d'appareil dominent l'explication du modèle.

Importance des Variables par Permutation



- Les variables les plus déterminantes sont account_tenure_days, transaction_amount et num_previous_transactions.
- Ces résultats soulignent l'importance de l'historique client et du comportement transactionnel dans la détection de fraude.

Analyse SHAP



Les nouvelles analyses d'interprétabilité SHAP démontrent que le modèle est maintenant plus robuste et plus fiable. Il base ses décisions sur des facteurs de risque logiques et reconnus.

Recommandations pour la Production

- Le Modèle Retenu : Le modèle final est un XGBoost optimisé. Il a été choisi pour sa capacité supérieure à capter les signaux de fraude faibles dans nos données.
- Performance Opérationnelle : Notre analyse a prouvé que la détection de fraude sur ce jeu de données est un problème difficile. Le modèle final est capable de détecter 37% des fraudes (Rappel). Cependant, cette détection a un coût : environ 9 prédictions de fraude sur 10 sont des fausses alertes (Précision de 9%).
- Conclusion Stratégique : Le modèle n'est pas assez fiable pour être utilisé comme un système de blocage entièrement automatique. Il doit être considéré comme un outil d'aide à la décision pour prioriser le travail des analystes.

Profil de transaction à haut risque :

- Compte récent, score IP élevé, temps sur site très court.
- Virement bancaire comme moyen de paiement.
- Montant modéré à élevé (100–300 €).

Pistes d'amélioration :

- Ajouter des données de livraison, comportementales et d'appareil.
- Exploiter l'historique transactionnel pour affiner la détection.